Université Sorbonne Paris Nord
UFR Sciences Économiques et de Gestion

Projet SQL-Python : Analyse de la Base ClassicModels

Réalisé par :

Khoubeib Bourbia

Année Universitaire 2025–2026

Table des matières

1 Introduction **6**

1.1 Contexte du projet . . . 6
1.2 Objectifs analytiques . . . 6
1.3 Outils utilisés . . . 6
1.4 Méthodologie générale . . . 6

2 Architecture et structuration des données **7**

2.1 Présentation synthétique de la base . . . 7
2.2 Logique relationnelle et organisation des flux . . . 7
2.3 Schéma EER . . . 7
2.4 Organisation technique du projet (SQL et Python) . . . 8

3 Analyse descriptive et performance globale **9**

3.1 Structure générale de l'activité . . . 9
3.2 Répartition géographique des clients et des ventes . . . 9
3.3 Performance financière globale . . . 10
3.4 Analyse par gamme de produits . . . 11
3.5 Produits les plus vendus . . . 11
3.6 Concentration du chiffre d'affaires et performance commerciale . . . 12

4 Analyses avancées et logique métier **13**

4.1 Dynamique temporelle des ventes (Window Functions) . . . 13
4.2 Structure organisationnelle (CTE récursif) . . . 13
4.3 Segmentation des clients . . . 13
4.4 Analyse d'ancienneté et de rétention . . . 14
4.5 Analyse pivot : ventes par gamme et trimestre . . . 14
4.6 Implémentation de la logique métier . . . 15
4.6.1 Procédure de calcul des commissions . . . 15
4.6.2 Procédure de gestion des stocks . . . 15
4.6.3 Fonction CLV . . . 15
4.6.4 Système d'audit . . . 15
4.6.5 Validation automatique du stock . . . 15
4.6.6 Mise à jour dynamique du statut client . . . 15

5 Analyses décisionnelles sous Python **17**

5.1 Analyse RFM (Recency – Frequency – Monetary) . . . 17
5.1.1 Méthodologie . . . 17
5.1.2 Statistiques descriptives RFM . . . 17
5.1.3 Segmentation des clients . . . 17
5.1.4 Performance économique par segment . . . 18
5.2 Analyse des corrélations et estimation de la satisfaction . . . 19
5.2.1 Analyse graphique des relations métier . . . 19
5.2.2 Construction du Customer Satisfaction Index (CSI) . . . 20
5.2.3 Lecture analytique synthétique . . . 20

5.3 Analyse des tendances temporelles 21
5.3.1 Évolution mensuelle des ventes et des commandes 21
5.3.2 Saisonnalité mensuelle 22
5.3.3 Analyse trimestrielle 22
5.4 Analyse du panier moyen et des associations produits 23
5.4.1 Structure et distribution du panier moyen 23
5.4.2 Analyse des associations produits 24
5.4.3 Lecture métier globale 24
5.5 Analyse des performances des employés et des bureaux 25
5.5.1 Performance individuelle des employés 25
5.5.2 Performance par bureau 26
5.5.3 Lecture stratégique globale 27

Conclusion générale **28**

Table des figures

2.1 Schéma relationnel de la base ClassicModels 8

3.1 Répartition des clients par pays 9
3.2 Répartition géographique des ventes 10
3.3 Distribution des montants de commande 10
3.4 Chiffre d'affaires par gamme de produits 11
3.5 Top 10 produits les plus vendus 11
3.6 Répartition du chiffre d'affaires (Top 10 vs Autres) 12
3.7 Top 5 employés par chiffre d'affaires 12

5.1 Analyse visuelle des principales corrélations 19
5.2 Évolution mensuelle du chiffre d'affaires et du nombre de commandes 21
5.3 Analyse saisonnière (mensuelle et trimestrielle) 22
5.4 Analyse du panier moyen : distribution, boxplot, évolution mensuelle et nombre de produits 23
5.5 Top 15 des paires de produits et associations par gamme 24
5.6 Indicateurs de performance par employé 25
5.7 Performance des bureaux (CA total et CA moyen par employé) 26

Liste des tableaux

3.1 Indicateurs structurels globaux 9
3.2 Indicateurs financiers 10

4.1 Mois les plus performants 13
4.2 Extrait des clients VIP 14
4.3 Ventes par gamme et par trimestre 14

5.1 Statistiques descriptives RFM 17
5.2 Répartition des segments RFM 18
5.3 Performance économique par segment 18
5.4 Statistiques descriptives du CSI 20

1 Introduction

1.1 Contexte du projet

Dans un contexte de digitalisation croissante des activités économiques, l'exploitation des bases de données relationnelles constitue un outil central d'analyse et d'aide à la décision. Ce projet, réalisé dans le cadre du module SQL, vise à mobiliser les techniques de gestion et d'interrogation de bases de données à partir de la base *ClassicModels*.

La base *ClassicModels* simule l'activité d'une entreprise spécialisée dans la vente de modèles réduits. Elle permet d'analyser la performance commerciale, la gestion de la relation client, l'organisation interne ainsi que les dynamiques temporelles des ventes dans un environnement relationnel structuré.

1.2 Objectifs analytiques

Ce projet poursuit plusieurs objectifs :

— Comprendre la structure et le fonctionnement d'une base relationnelle complète ;
— Mettre en œuvre des requêtes SQL descriptives et avancées (fonctions analytiques, requêtes récursives, sous-requêtes corrélées) ;
— Implémenter des logiques métier via procédures stockées, fonctions et déclencheurs ;
— Construire des indicateurs de performance commerciale ;
— Exploiter les données sous Python pour réaliser des analyses et visualisations décisionnelles.

L'objectif global est d'articuler rigueur technique et interprétation économique des résultats obtenus.

1.3 Outils utilisés

La réalisation du projet repose sur les outils suivants :

— **MySQL** pour la gestion et l'exploitation des données ;
— **MySQL Workbench** pour la modélisation et la rétro-ingénierie du schéma ;
— **Python** (pandas, matplotlib, seaborn, plotly) pour l'analyse et la visualisation ;
— Un environnement structuré combinant scripts SQL et notebooks analytiques.

Cette combinaison assure une continuité entre extraction, traitement et analyse décisionnelle.

1.4 Méthodologie générale

La démarche adoptée s'est organisée en quatre étapes :

1. Analyse de l'architecture relationnelle et des liens entre entités ;
2. Réalisation d'analyses descriptives et identification des principaux indicateurs ;
3. Implémentation de requêtes SQL avancées intégrant des logiques analytiques ;
4. Approfondissement de l'analyse via Python pour une interprétation stratégique.

2 Architecture et structuration des données

2.1 Présentation synthétique de la base

La base *ClassicModels* modélise l'activité d'une entreprise fictive spécialisée dans la vente de modèles réduits. Elle comprend huit tables interconnectées couvrant les dimensions commerciales, financières et organisationnelles.

Les principales tables sont :

— **customers** : informations clients (coordonnées, pays, limite de crédit, commercial) ;
— **orders** : commandes effectuées ;
— **orderdetails** : détail des produits par commande ;
— **products** : catalogue des produits ;
— **productlines** : catégories de produits ;
— **payments** : historique des paiements ;
— **employees** : données relatives aux employés ;
— **offices** : localisation des bureaux.

Cette structuration permet d'analyser la performance commerciale, la relation client ainsi que l'organisation interne de l'entreprise.

2.2 Logique relationnelle et organisation des flux

L'architecture repose sur une logique transactionnelle centrée sur les commandes.
La table **customers** constitue le point d'entrée du processus commercial.Un client peut passer plusieurs commandes (relation un-à-plusieurs avec **orders**). Chaque commande est détaillée via **orderdetails**, table pivot reliant les transactions aux produits vendus.
La table **orderdetails** relie ainsi les informations quantitatives (quantité, prix unitaire) aux caractéristiques produits stockées dans **products**, elles-mêmes regroupées par catégorie via **productlines**. Cette organisation facilite l'analyse de la performance par gamme. La table **payments**, associée aux clients, permet d'étudier les flux financiers et le chiffre d'affaires.
Sur le plan organisationnel, **employees** est reliée à **offices** pour l'analyse géographique. La présence du champ récursif *reportsTo* permet de modéliser la hiérarchie interne et d'étudier la performance par niveau managérial.

2.3 Schéma EER

La figure suivante présente le schéma entité-association obtenu par rétro-ingénierie.

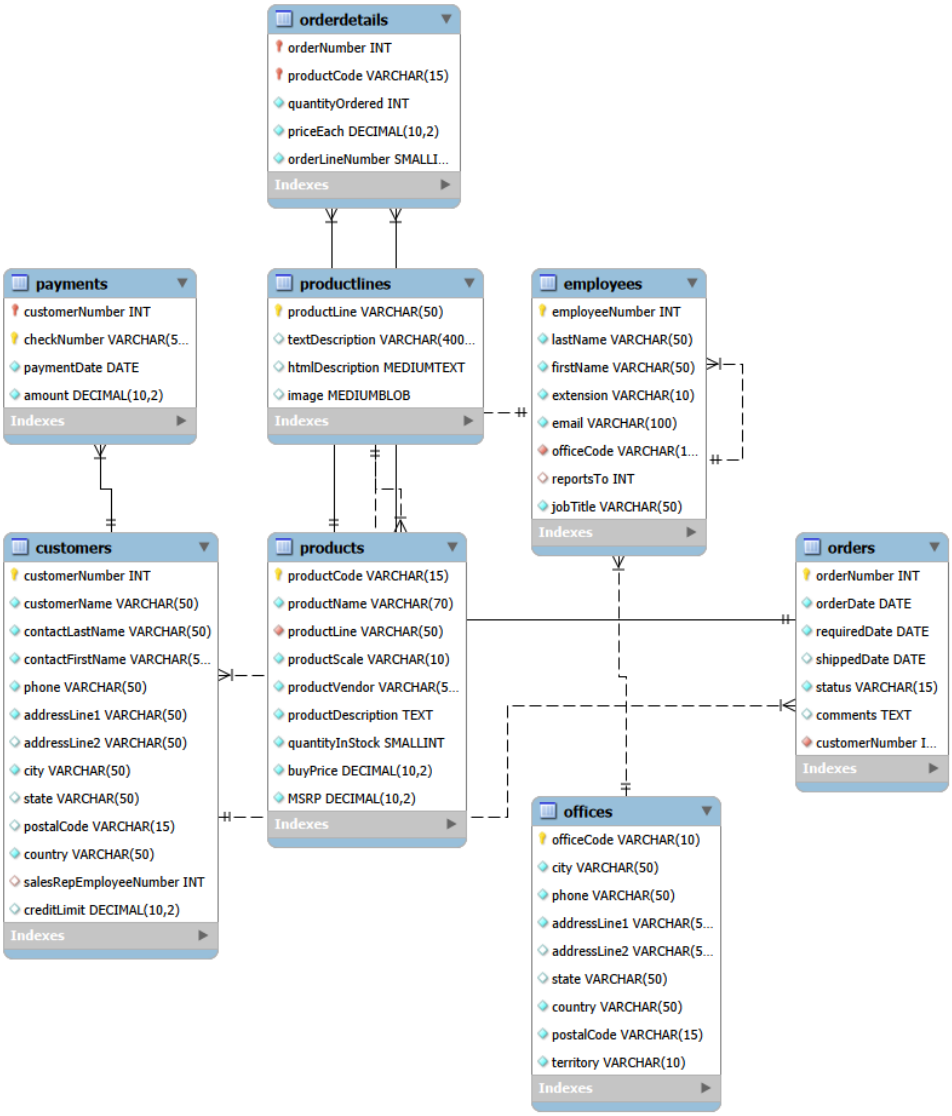


FIGURE 2.1 – Schéma relationnel de la base ClassicModels

Ce schéma met en évidence la centralité des tables **customers**, **orders** et **orderdetails** dans la dynamique transactionnelle, ainsi que la distinction entre dimension commerciale et organisationnelle.

2.4 Organisation technique du projet (SQL et Python)

Le projet a été structuré selon une logique d'extraction, de transformation et d'analyse.

La partie **SQL** comprend :

— Les requêtes descriptives et indicateurs clés ;

— Les requêtes avancées (fonctions analytiques, requêtes récursives) ;

— Les procédures stockées, fonctions et déclencheurs implémentant la logique métier.

La partie **Python** est consacrée à :

— L'exploitation des résultats SQL ;

— La production de visualisations ;

— L'approfondissement de l'analyse décisionnelle.

3 Analyse descriptive et performance globale

3.1 Structure générale de l'activité

L'analyse des volumes globaux permet d'évaluer la dimension structurelle et l'intensité commerciale de l'entreprise.

Indicateur	Valeur
Clients	122
Employés	22
Bureaux	7
Commandes	327
Produits	110
Gammes	7

TABLE 3.1 – Indicateurs structurels globaux

L'organisation est relativement compacte : 22 employés répartis sur 7 bureaux gèrent 122 clients. Le ratio commandes/clients (≈ 2,68) traduit une relation commerciale active. Le catalogue, composé de 110 produits répartis en 7 gammes,indique une diversification modérée.

3.2 Répartition géographique des clients et des ventes

La dimension géographique constitue un enjeu stratégique majeur.

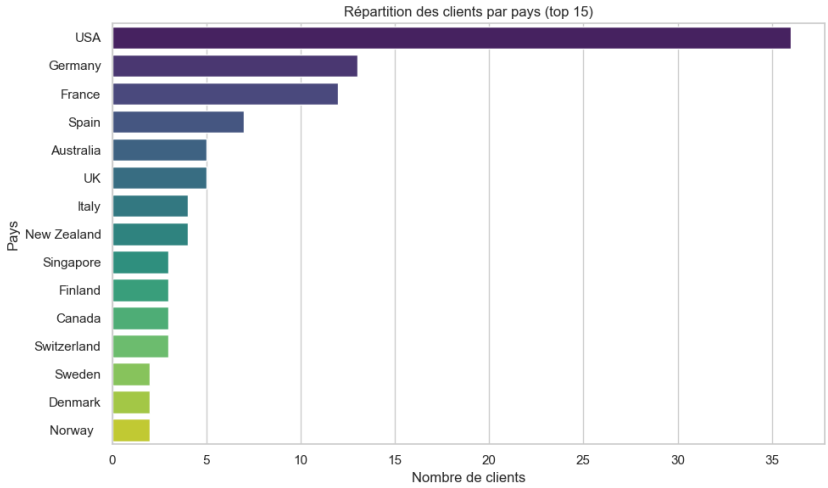


FIGURE 3.1 – Répartition des clients par pays

Les États-Unis concentrent 36 clients (près de 30 %), suivis de l'Allemagne (13) et de la France (12). Cette dépendance au marché nord-américain représente à la fois une force et un risque potentiel.



FIGURE 3.2 – Répartition géographique des ventes

La distribution des ventes confirme cette concentration dans les économies développées, avec une présence limitée sur les marchés émergents.

3.3 Performance financière globale

Indicateur	**Valeur**
Chiffre d'affaires total	9 604 190.61 USD
Panier moyen	29 460.71 USD

TABLE 3.2 – Indicateurs financiers

Le niveau de chiffre d'affaires reflète une activité significative, avec un panier moyen élevé suggérant un positionnement à valeur ajoutée.

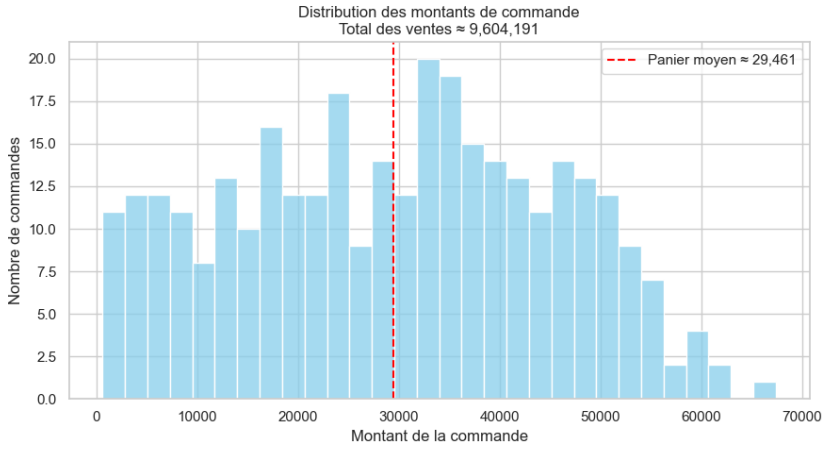


FIGURE 3.3 – Distribution des montants de commande

L'histogramme montre une distribution concentrée autour du panier moyen, avec quelques commandes de montant plus élevé contribuant fortement au chiffre d'affaires global. Cette structure indique une relative homogénéité des commandes, limitant la dépendance excessive à quelques transactions exceptionnelles.

3.4 Analyse par gamme de produits

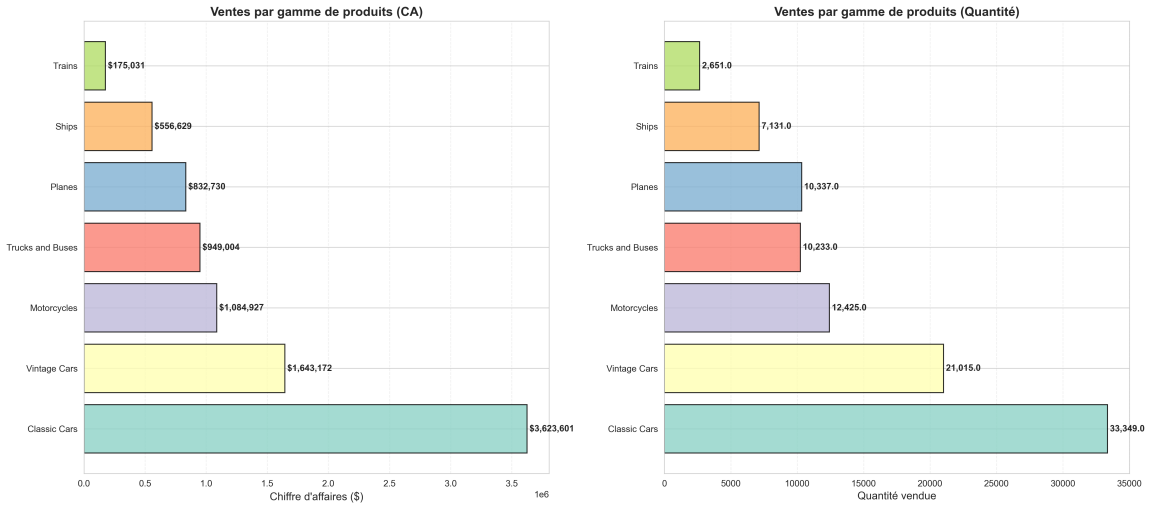


FIGURE 3.4 – Chiffre d'affaires par gamme de produits

La gamme *Classic Cars* domine avec 3 853 922.49 USD, constituant le principal moteur de revenus. Cette concentration sectorielle peut refléter un avantage compétitif clair sur ce segment. Toutefois, elle implique également une dépendance stratégique : une baisse de la demande sur cette gamme aurait un impact significatif sur la performance globale

3.5 Produits les plus vendus

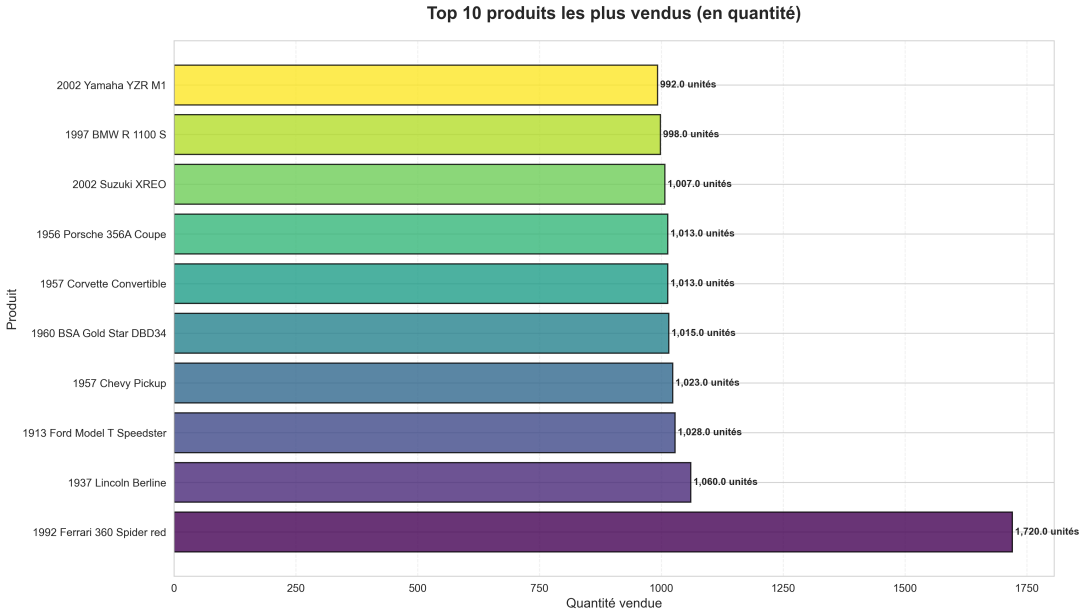


FIGURE 3.5 – Top 10 produits les plus vendus

Le modèle *1992 Ferrari 360 Spider red* arrive en tête avec 1 808 unités vendues. La dispersion progressive entre les produits du top 10 traduit une concentration modérée et une diversification saine du

catalogue.

3.6 Concentration du chiffre d'affaires et performance commerciale

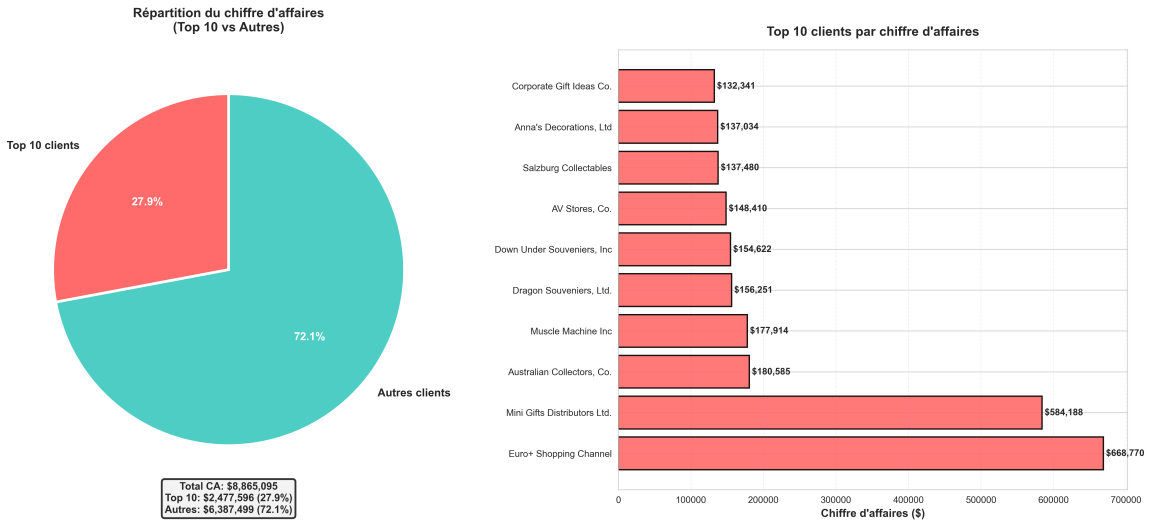


FIGURE 3.6 – Répartition du chiffre d'affaires (Top 10 vs Autres)

Les dix principaux clients représentent environ 27,9 % du chiffre d'affaires total, ce qui indique une base client relativement diversifiée.

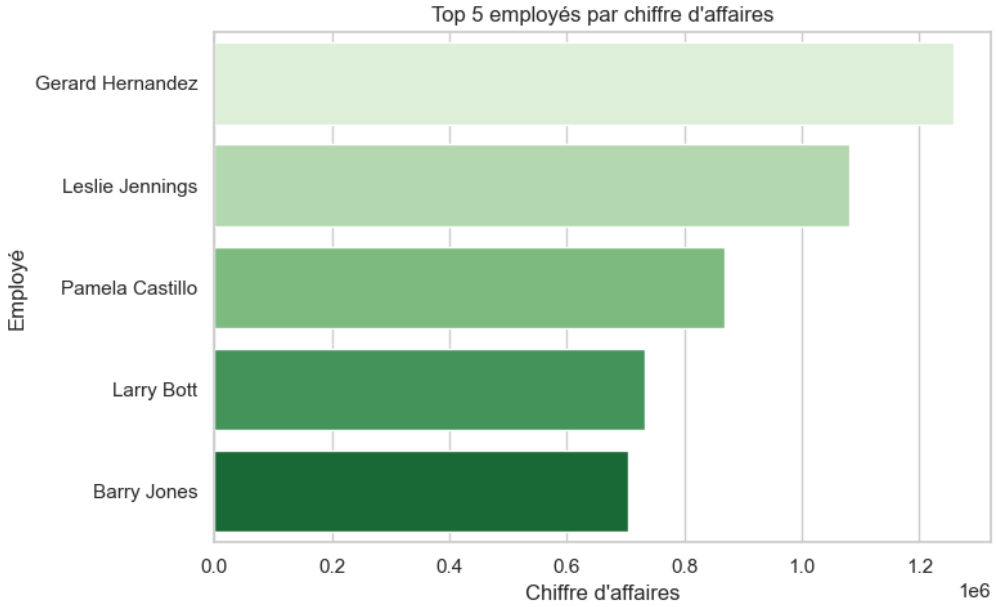


FIGURE 3.7 – Top 5 employés par chiffre d'affaires

Gerard Hernandez (Sales Rep) se distingue avec 1 258 577.81 USD de chiffre d'affaires. La performance commerciale dépend donc fortement de l'efficacité individuelle et du portefeuille client géré.

4 Analyses avancées et logique métier

Cette section présente les traitements SQL avancés mobilisant des fonctionnalités telles que les *window functions*, CTE récursifs, sous-requêtes corrélées et pivot. L'objectif est d'introduire une dimension décisionnelle à partir des données transactionnelles.

4.1 Dynamique temporelle des ventes (Window Functions)

Les ventes mensuelles (commandes *Shipped*) ont été analysées via :

— cumul des ventes,

— moyenne mobile sur trois mois,

— pourcentage du total,

— classement mensuel.

Mois	Montant (USD)	% du total	Rang
2003-11	965 061.55	10.89 %	1
2004-11	935 712.95	10.56 %	2
2004-10	500 233.86	5.64 %	3
2003-10	443 047.22	5.00 %	4
2004-12	428 838.17	4.84 %	5

TABLE 4.1 – Mois les plus performants

On observe une forte concentration en fin d'année, notamment en novembre 2003 et 2004, confirmant un effet saisonnier marqué. La moyenne mobile révèle une croissance entre 2003 et 2004, suivie d'une stabilisation en 2005. Ces résultats sont stratégiques pour la planification des stocks et des ressources commerciales.

4.2 Structure organisationnelle (CTE récursif)

La hiérarchie interne a été reconstruite via un CTE récursif basé sur *reportsTo* :

— Niveau 0 : Diane Murphy – President

— Niveau 1 : Vice-Présidents (Sales, Marketing)

— Niveau 2 : Managers régionaux (APAC, EMEA, NA)

— Niveau 3 : Sales Representatives

La majorité des employés se situe au niveau 3, correspondant à la force commerciale. Cette modélisation arborescente permet d'analyser les performances par niveau hiérarchique et par région.

4.3 Segmentation des clients

Une segmentation a été réalisée selon le chiffre d'affaires :

— VIP : $\geq$ 150 000 USD

— Régulier : 50 000 – 149 999 USD

— Petit client : $<$ 50 000 USD

Client	Pays	CA (USD)	Cmd	Segment
Euro+ Shopping Channel	Spain	820 689.54	26	VIP
Mini Gifts Distributors Ltd.	USA	591 827.34	17	VIP
Australian Collectors, Co.	Australia	180 585.07	5	VIP
Muscle Machine Inc	USA	177 913.95	4	VIP
La Rochelle Gifts	France	158 573.12	4	VIP

Table 4.2 – Extrait des clients VIP

Les VIP concentrent une part significative des revenus et nécessitent un suivi personnalisé. Les petits clients représentent un potentiel de développement.

4.4 Analyse d'ancienneté et de rétention

À partir des dates MIN(orderDate) et MAX(orderDate), Un seuil de 6 mois a été utilisé pour classifier les clients selon deux dimensions :

— Type : Nouveau, Ancien, Jamais commandé

— Rétention : Retenu, Perdu, Jamais commandé

Trois cas apparaissent :

1. Clients jamais commandé : comptes inactifs ou prospects non convertis.
2. Clients Ancien – Retenu : noyau stable du portefeuille.
3. Clients Ancien – Perdu : attrition partielle.

Cette analyse transforme des dates transactionnelles en indicateurs de cycle de vie client.

4.5 Analyse pivot : ventes par gamme et trimestre

Gamme	T1	T2	T3	T4	Total
Classic Cars	868 487.88	798 229.99	690 564.27	1 496 640.35	3 853 922.49
Vintage Cars	437 120.54	367 442.32	312 313.60	680 683.17	1 797 559.63
Motorcycles	231 128.35	301 788.99	192 440.08	396 068.70	1 121 426.12
Trucks and Buses	212 868.76	217 234.66	180 676.06	413 334.09	1 024 113.57
Planes	218 112.72	229 116.52	125 643.53	381 764.77	954 637.54
Ships	175 041.38	132 924.33	109 255.20	246 777.43	663 998.34
Trains	47 074.38	34 585.47	34 692.96	72 180.11	188 532.92

Table 4.3 – Ventes par gamme et par trimestre

On observe :

— Une domination constante de *Classic Cars* ;

— Un pic généralisé au T4 ;

— Une contribution marginale des *Trains*.

Cela confirme la saisonnalité de fin d'année et la spécialisation stratégique.

4.6 Implémentation de la logique métier

4.6.1 Procédure de calcul des commissions

La procédure *CalculateEmployeeCommission* calcule :

— le total des ventes expédiées,

— une commission de 5 %.

Elle automatise l'évaluation des performances commerciales.

4.6.2 Procédure de gestion des stocks

La procédure *ManageStock* :

— vérifie la disponibilité d'un produit,

— met à jour le stock apres une commande,

— classe le niveau (NORMAL, FAIBLE, CRITIQUE, INSUFFISANT).

Seuils : 50 unités (réapprovisionnement) et 20 unités (critique).

Cette procédure transforme la base en outil de gestion logistique. Elle permet d'anticiper les ruptures, d'identifier les produits à risque et d'améliorer la planification des approvisionnements. Elle introduit ainsi une dimension opérationnelle essentielle pour une entreprise commerciale.

4.6.3 Fonction CLV

La fonction *CustomerLifetimeValue* calcule la valeur totale des commandes expédiées d'un client. Elle formalise un indicateur clé de contribution économique.

Cette fonction formalise un indicateur clé en gestion de la relation client :

— la contribution économique totale d'un client.

— Elle peut être utilisée pour :

— classer les clients par valeur,

— identifier les clients stratégiques,

— alimenter des analyses de segmentation.

4.6.4 Système d'audit

Un ensemble de triggers (INSERT, UPDATE, DELETE) a été mis en place afin d'enregistrer automatiquement toute modification apportée à la table orders dans une table d'audit dédiée. Les informations enregistrées comprennent :

— le type d'action,

— l'ancien et le nouveau statut,

— l'utilisateur ayant effectué l'action,

— la date de modification.

4.6.5 Validation automatique du stock

Le trigger *validate_stock_before_order* empêche une commande si le stock est insuffisant, assurant la cohérence transactionnelle.

4.6.6 Mise à jour dynamique du statut client

Un trigger met automatiquement à jour *customerStatus* (VIP, Régulier, Actif, Inactif) selon :

— montant total dépensé,
— nombre de commandes.

5 Analyses décisionnelles sous Python

5.1 Analyse RFM (Recency – Frequency – Monetary)

5.1.1 Méthodologie

L'analyse RFM est une méthode de segmentation comportementale reposant sur trois dimensions :

— **Recency (R)** : nombre de jours depuis la dernière commande ;

— **Frequency (F)** : nombre total de commandes effectuées ;

— **Monetary (M)** : montant total dépensé par le client.

L'échantillon comprend 98 clients actifs (ayant au moins une commande).

Les scores (1 à 4) sont attribués selon une logique de quartiles :

— Score 4 : meilleur quartile (top 25 %)

— Score 1 : quartile le plus faible

Spécificité méthodologique :

— Pour **Recency**, la logique est inversée : plus le nombre de jours est faible, plus le score est élevé.

— Pour **Frequency** et **Monetary**, plus la valeur est élevée, plus le score est élevé.

Cette standardisation permet une segmentation homogène et comparable.

5.1.2 Statistiques descriptives RFM

Indicateur	Recency	Frequency	Monetary (USD)
Moyenne	194.58 jours	3.09	90 460
Médiane	181 jours	3	76 357
Maximum	546 jours	22	668 770
Minimum	0 jour	1	7 918

Table 5.1 – Statistiques descriptives RFM

Interprétation :

— Forte dispersion sur la variable Monetary, traduisant une hétérogénéité de valeur client.

— Fréquence moyenne relativement faible (≈ 3 commandes).

— Recency moyenne élevée ($\approx$ 195 jours), indiquant qu'une partie des clients n'a pas commandé récemment.

5.1.3 Segmentation des clients

La segmentation repose sur la combinaison des scores R, F et M :

— **VIP** : $R \geq 3$, $F \geq 3$, $M \geq 3$

— **Régulier** : $R \geq 2$, $F \geq 2$, $M \geq 2$

— **À risque** : $R \geq 2$ mais $F = 1$ ou $M = 1$

— **Perdu** : autres cas

Segment	Nombre de clients
VIP	13
Régulier	36
À risque	25
Perdu	24

TABLE 5.2 – Répartition des segments RFM

Analyse :

— Le segment **Régulier** est majoritaire.

— Environ 25 % des clients sont classés **À risque**.

— Les **VIP** représentent 13 % de l'échantillon.

5.1.4 Performance économique par segment

Segment	Nb	CA total	CA moyen	Freq. moy.	Recency moy.
VIP	13	2 774 009	213 385	6.62	69 j
Régulier	36	3 296 388	91 566	3.06	124 j
À risque	25	1 305 756	52 230	2.24	172 j
Perdu	24	1 488 939	62 039	2.12	390 j

TABLE 5.3 – Performance économique par segment

Interprétation stratégique

Segment VIP

— Recency faible (≈ 69 jours)

— Fréquence élevée (6.6 commandes)

— CA moyen supérieur à 213 000 USD

→ Segment stratégique à forte valeur.

Segment Régulier

— Segment majoritaire

— Génère le CA total le plus élevé

→ Fort potentiel d'upsell vers VIP.

Segment À risque

— Recency élevée (≈ 172 jours)

— Fréquence modérée

→ Nécessite des actions de relance ciblées.

Segment Perdu

— Recency très élevée (≈ 390 jours)

— Contribution économique limitée

→ Stratégie de réactivation ou abandon stratégique.

5.2 Analyse des corrélations et estimation de la satisfaction

5.2.1 Analyse graphique des relations métier

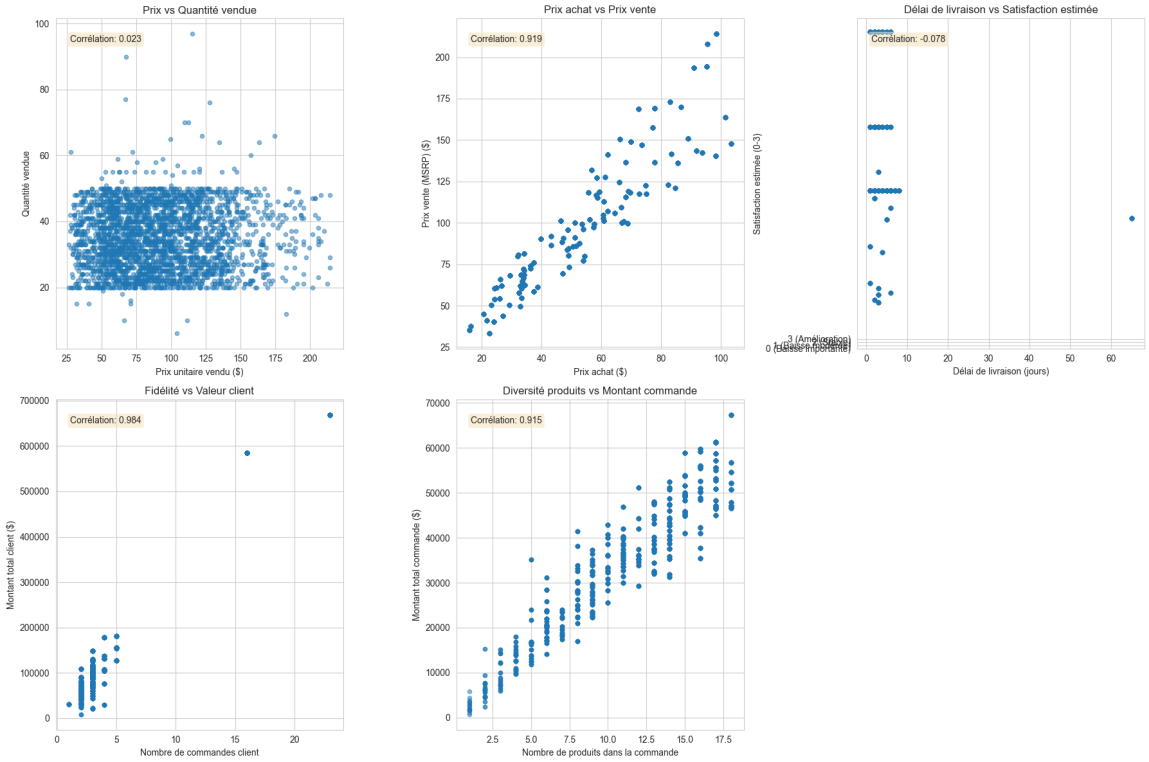


FIGURE 5.1 – Analyse visuelle des principales corrélations

La figure regroupe cinq relations clés étudiées dans cette analyse :

— La relation entre prix unitaire et quantité vendue apparaît extrêmement dispersée. Les points ne suivent aucune tendance structurée, ce qui confirme que les volumes ne sont pas significativement influencés par le niveau de prix. La demande semble relativement stable quel que soit le positionnement tarifaire.

— La relation entre prix d'achat et prix de vente est, à l'inverse, fortement linéaire. Les points s'alignent de manière quasi proportionnelle, traduisant une politique de marge cohérente et homogène. L'entreprise applique une structure de pricing stable, sans distorsion excessive.

— La relation entre délai de livraison et satisfaction estimée montre une légère pente négative. Les délais plus longs tendent à être associés à des niveaux de satisfaction légèrement inférieurs. Toutefois, la dispersion reste importante, ce qui indique que la logistique n'est pas le facteur principal du comportement futur.

— Le graphique fidélité versus valeur client met en évidence une relation quasi proportionnelle entre le nombre de commandes et le montant total généré. La valeur d'un client augmente principalement par la répétition d'achat, ce qui souligne l'importance stratégique de la fidélisation.

— Enfin, la relation entre diversité des produits et montant de la commande montre une progression claire : plus un panier contient de produits distincts, plus son montant global augmente. Cette dynamique confirme le rôle du cross-selling dans l'augmentation du chiffre d'affaires par transaction.

5.2.2 Construction du Customer Satisfaction Index (CSI)

En l'absence de mesure déclarative, un indicateur comportemental a été construit.

Le CSI repose sur l'évolution du comportement d'achat entre deux périodes successives de six mois :

— évolution du panier moyen,

— évolution de la fréquence d'achat.

Une progression simultanée entraîne un score élevé, une contraction un score faible. Le score est normalisé sur une échelle de 0 à 100.

Indicateur	**Valeur**
Nombre d'observations	2 771
Moyenne	52.23
Écart-type	12.76
Minimum	14.53
Médiane	50
Maximum	100

Table 5.4 – Statistiques descriptives du CSI

La distribution est centrée autour d'un niveau intermédiaire, indiquant une stabilité globale du comportement client, avec une minorité connaissant des variations significatives.

5.2.3 Lecture analytique synthétique

L'analyse combinée des corrélations et du CSI met en évidence que :

— la performance commerciale repose principalement sur la fréquence d'achat ;

— la diversification du panier constitue un levier direct de croissance ;

— la politique de prix est structurellement cohérente ;

— les délais logistiques ont un impact relativement limité.

La dynamique relationnelle avec le client apparaît ainsi comme le principal moteur de création de valeur dans la base *ClassicModels*.

5.3 Analyse des tendances temporelles

5.3.1 Évolution mensuelle des ventes et des commandes

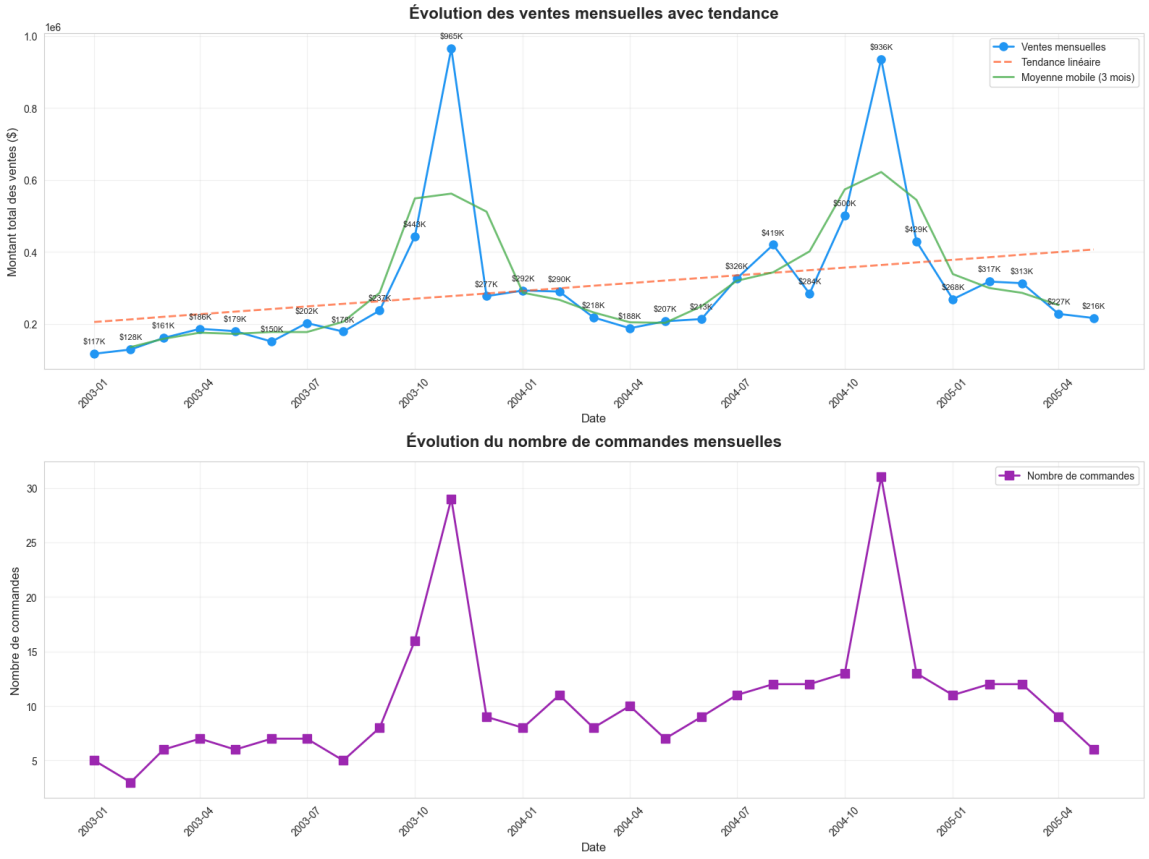


FIGURE 5.2 – Évolution mensuelle du chiffre d'affaires et du nombre de commandes

L'analyse de la série temporelle met en évidence une tendance générale positive. La droite de tendance confirme une croissance progressive du chiffre d'affaires mensuel, traduisant une expansion maîtrisée.
La moyenne mobile sur trois mois lisse les variations ponctuelles et révèle des cycles récurrents. Les pics observés en fin d'année, notamment au quatrième trimestre, se distinguent nettement.
Le suivi simultané du nombre de commandes montre que les pics de chiffre d'affaires correspondent à une hausse du volume de commandes. La croissance repose donc à la fois sur l'intensification de l'activité et sur la valeur des transactions.
La variabilité mensuelle importante suggère un effet saisonnier marqué.

5.3.2 Saisonnalité mensuelle

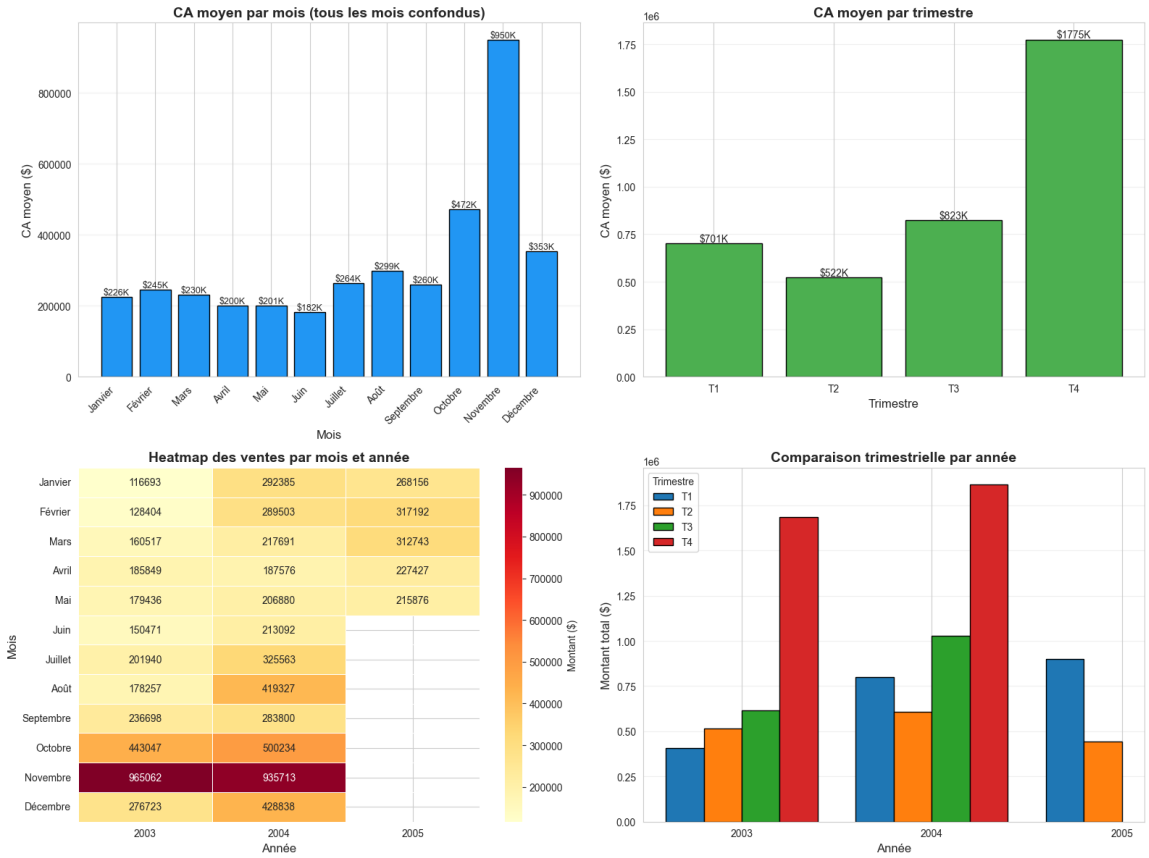


FIGURE 5.3 – Analyse saisonnière (mensuelle et trimestrielle)

L'analyse du chiffre d'affaires moyen par mois confirme une saisonnalité structurée.
Les mois d'octobre, novembre et décembre sont systématiquement les plus performants, avec un pic très marqué en novembre. À l'inverse, avril, mai et juin enregistrent les niveaux les plus faibles.
La heatmap annuelle montre que le quatrième trimestre concentre les ventes les plus élevées sur l'ensemble des années observées. L'écart significatif entre les mois les plus performants et les plus faibles confirme une dépendance saisonnière importante.

5.3.3 Analyse trimestrielle

L'agrégation par trimestre révèle une hiérarchie stable :

— Le quatrième trimestre est systématiquement le plus performant ;
— Le troisième trimestre occupe une position intermédiaire ;
— Le premier trimestre présente un niveau modéré ;
— Le deuxième trimestre est le plus faible.

Cette structure répétée sur plusieurs années indique une saisonnalité structurelle et non accidentelle.

5.4 Analyse du panier moyen et des associations produits

5.4.1 Structure et distribution du panier moyen

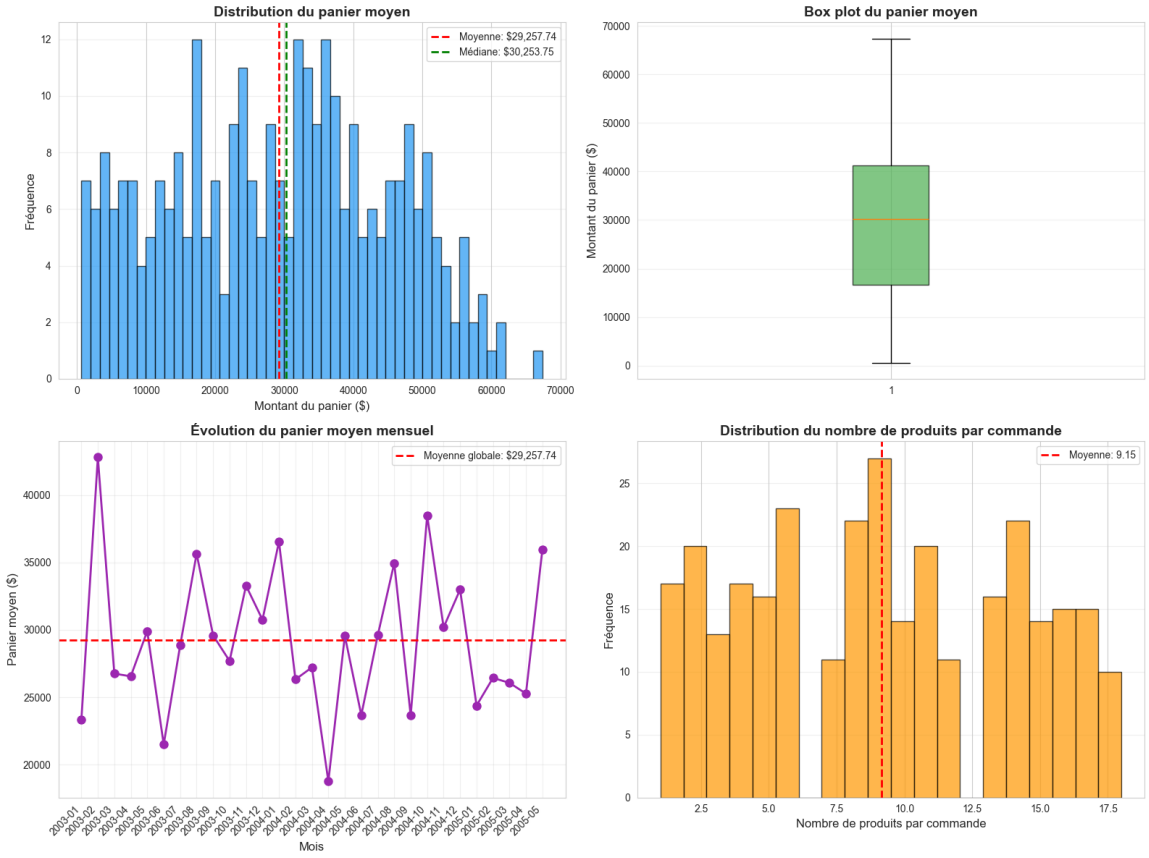


FIGURE 5.4 – Analyse du panier moyen : distribution, boxplot, évolution mensuelle et nombre de produits

La distribution du panier montre une structure relativement équilibrée. La moyenne et la médiane sont proches, indiquant l'absence de distorsion majeure causée par quelques commandes extrêmes. Le panier moyen reflète donc fidèlement le comportement typique des clients.

Le boxplot confirme cette stabilité :

— Dispersion modérée ;

— Quelques valeurs élevées sans domination excessive ;

— Concentration autour d'un niveau central cohérent.

L'écart-type reste significatif, traduisant une variabilité naturelle entre petits et grands acheteurs.

Lecture dynamique :

L'évolution mensuelle montre que les variations ne sont pas aléatoires. Certains mois présentent des pics, cohérents avec la saisonnalité observée précédemment. Ainsi, la croissance du chiffre d'affaires ne repose pas uniquement sur le volume de commandes, mais aussi sur la variation du panier moyen.

Nombre de produits par commande :

La distribution est homogène, avec moyenne et médiane alignées. La commande type contient plusieurs articles, confirmant un comportement naturellement orienté vers le multi-produit.

5.4.2 Analyse des associations produits

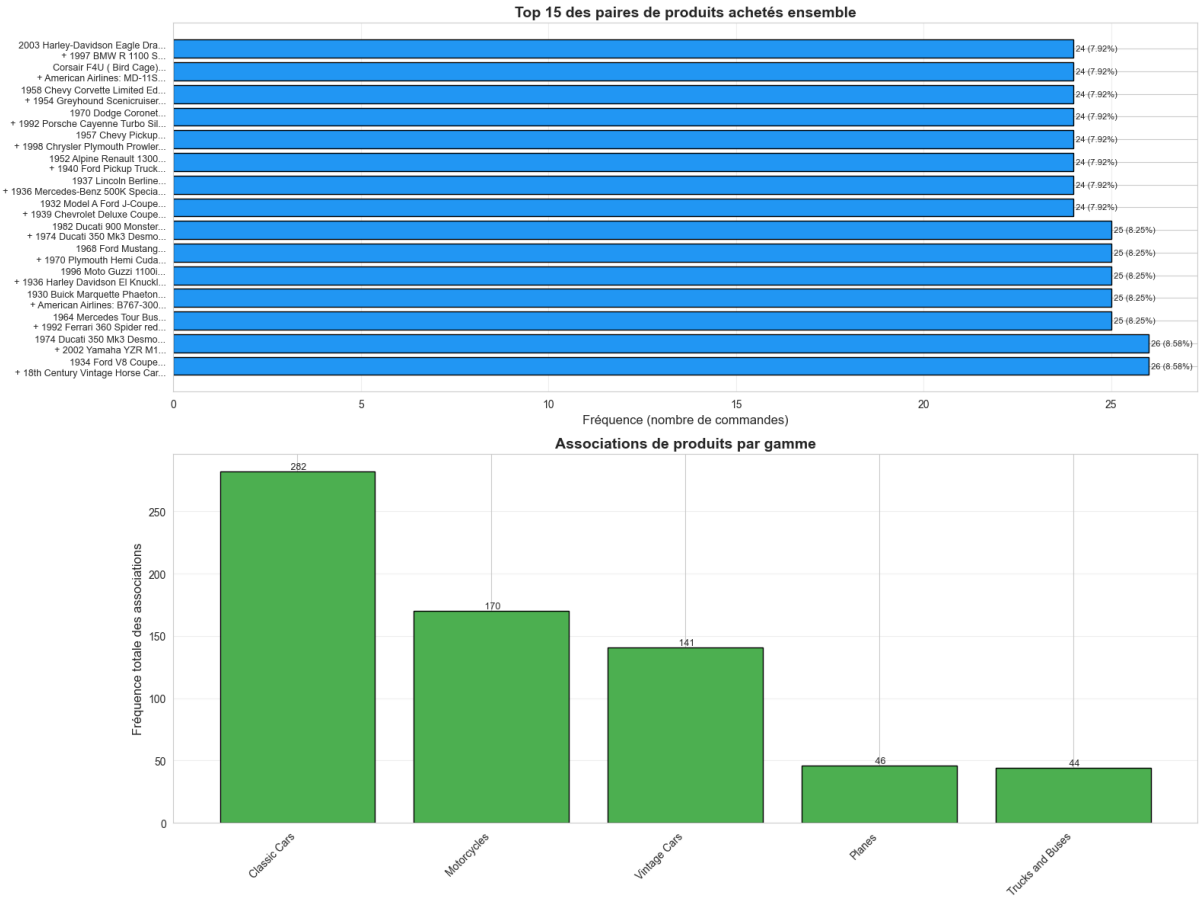


FIGURE 5.5 – Top 15 des paires de produits et associations par gamme

L'analyse des paires révèle une grande diversité de combinaisons, indiquant une exploitation transversale du catalogue. Toutefois, certaines associations sont nettement récurrentes et traduisent des préférences structurelles.

Lecture stratégique :

— Les combinaisons les plus fréquentes appartiennent souvent à la même gamme ;

— Les achats intra-gamme sont plus naturels que les achats inter-gammes ;

— La gamme *Classic Cars* domine en nombre d'associations.

Certaines associations inter-gammes existent néanmoins, ouvrant des opportunités de cross-sell ciblé.

5.4.3 Lecture métier globale

L'analyse du panier met en évidence trois éléments structurants :

— Le panier moyen est stable et représentatif ;

— Les clients achètent naturellement plusieurs produits ;

— Les associations intra-gamme sont dominantes.

Implications décisionnelles :

— Le levier principal n'est pas l'augmentation du prix unitaire ;

— Le levier prioritaire est l'augmentation de la diversité au sein d'une commande ;

— Les recommandations peuvent s'appuyer sur les paires fréquentes observées.

La base transactionnelle présente ainsi un fort potentiel pour :
— la création de bundles produits,
— des suggestions automatiques,
— des offres packagées par gamme.

5.5 Analyse des performances des employés et des bureaux

5.5.1 Performance individuelle des employés

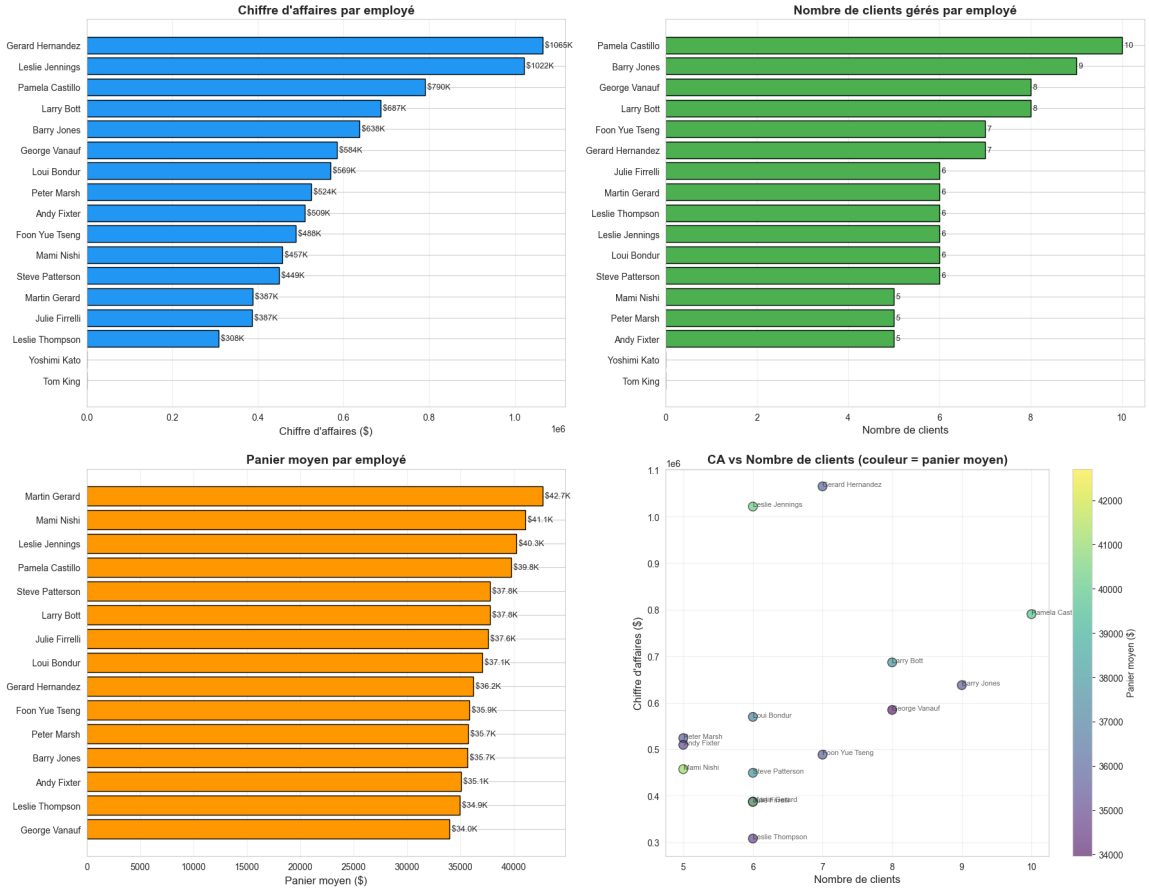


FIGURE 5.6 – Indicateurs de performance par employé

(Cette figure regroupe : chiffre d'affaires, nombre de clients gérés, panier moyen et relation CA vs clients.)

1) Chiffre d'affaires par employé

Le chiffre d'affaires total généré par l'ensemble des commerciaux s'élève à 8,87 M USD, avec :
— un CA moyen par employé d'environ 521 000 USD ;
— une médiane proche de la moyenne, indiquant une distribution relativement équilibrée.
Une concentration apparaît toutefois autour de certains profils :
— Gerard Hernandez dépasse le million USD ;
— Leslie Jennings atteint un niveau comparable ;
— un groupe intermédiaire se situe autour de la moyenne ;
— deux employés n'ont généré aucun chiffre d'affaires.

La performance n'est donc pas homogène : certains commerciaux jouent un rôle moteur dans la génération du revenu global.

2) Nombre de clients gérés

Le nombre moyen de clients par employé est d'environ 6, traduisant une répartition relativement équilibrée du portefeuille.

Cependant :

— un plus grand nombre de clients n'implique pas nécessairement un CA plus élevé ;

— certains employés avec un portefeuille réduit génèrent un chiffre d'affaires supérieur.

La qualité du portefeuille semble ainsi plus déterminante que sa taille.

3) Panier moyen par employé

Le panier moyen global est d'environ 37 400 USD.

On observe deux logiques :

— certains employés génèrent un CA élevé grâce au volume de commandes ;

— d'autres compensent un portefeuille réduit par un panier moyen important.

Martin Gerard présente le panier moyen le plus élevé.

Deux stratégies commerciales se distinguent :

— stratégie volume (augmentation du nombre de commandes) ;

— stratégie valeur (augmentation du panier moyen).

4) Relation CA et Nombre de clients

Le graphique croisé (CA vs nombre de clients, couleur = panier moyen) montre que :

— la performance élevée peut provenir d'un portefeuille large ;

— ou d'un panier moyen supérieur ;

— ou d'une combinaison des deux.

Les profils les plus performants combinent un nombre raisonnable de clients et un panier moyen solide, confirmant qu'une stratégie équilibrée est plus stable qu'une approche extrême.

5.5.2 Performance par bureau

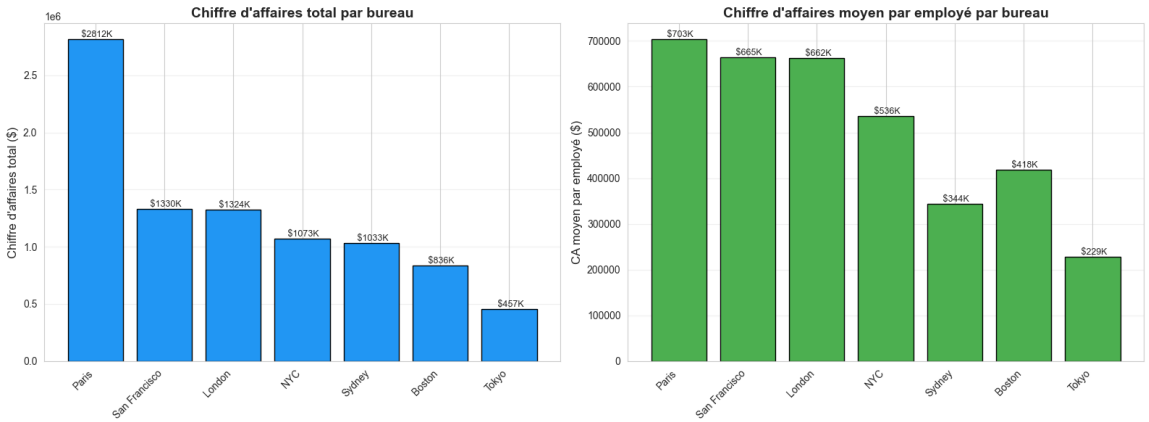


FIGURE 5.7 – Performance des bureaux (CA total et CA moyen par employé)

1) Chiffre d'affaires total par bureau

Le bureau de Paris domine en chiffre d'affaires total, suivi de San Francisco et London. Tokyo et Boston affichent des volumes plus modestes.

Ces écarts peuvent s'expliquer par :

— la taille du portefeuille local ;
— la dynamique économique régionale ;
— la performance individuelle des employés affectés.

2) Chiffre d'affaires moyen par employé

L'analyse du CA moyen par employé met en évidence que :

— certains bureaux avec peu d'employés affichent une performance moyenne élevée ;
— d'autres, plus importants en effectif, présentent une moyenne plus faible.

La performance globale d'un bureau dépend donc :

— du nombre d'employés ;
— mais surtout de leur efficacité individuelle.

5.5.3 Lecture stratégique globale

Cette analyse montre que :

— la performance n'est pas uniquement liée au volume de clients ;
— le panier moyen joue un rôle structurant ;
— certains bureaux concentrent les meilleurs profils ;
— une hétérogénéité interne importante existe.

Implications décisionnelles :

— les meilleures pratiques des employés performants peuvent être modélisées ;
— une harmonisation des stratégies commerciales pourrait réduire les écarts ;
— l'optimisation du panier moyen constitue un levier aussi important que l'acquisition de nouveaux clients.

Conclusion générale

Ce projet a permis d'exploiter la base *ClassicModels* dans une logique complète d'analyse décisionnelle, allant de la structuration relationnelle en SQL jusqu'aux analyses avancées sous Python. L'approche adoptée a articulé rigueur technique, modélisation des données et interprétation stratégique des résultats.

Les analyses mettent en évidence plusieurs éléments structurants :

- Une trajectoire de croissance positive sur la période étudiée, combinée à une saisonnalité marquée en fin d'année, traduisant un cycle commercial structurel.
- Une valeur client fortement corrélée à la fréquence d'achat, confirmée par l'analyse RFM et l'étude des corrélations. La fidélisation apparaît ainsi comme le principal moteur de création de valeur.
- Une structure de panier stable et représentative, caractérisée par des associations produits cohérentes et un potentiel significatif de cross-selling.
- Des écarts de performance notables entre employés et bureaux, soulignant l'importance du pilotage commercial, de la gestion des portefeuilles clients et de la diffusion des meilleures pratiques.
- Un impact modéré du délai logistique sur la satisfaction estimée, celle-ci étant davantage liée à l'évolution du comportement d'achat qu'à des variables transactionnelles isolées.

Au-delà des résultats chiffrés, ce projet illustre la capacité d'une base transactionnelle à devenir un véritable outil d'aide à la décision lorsqu'elle est exploitée à travers des méthodes analytiques structurées. L'intégration de requêtes SQL avancées, de logique métier automatisée et d'analyses statistiques sous Python permet de transformer des données opérationnelles en leviers stratégiques concrets.